

1. Proje ismi
Makine Öğrenmesi ve Derin Öğrenme Yöntemleri ile Görüntü Tabanlı Yangın Tespiti
2. Github Linki
https://github.com/bunveren/YAP470
3. Yöntemi uygularken kullanılan veri setleri ve linkleri (girdi, çıktı, öznitelikler, sayı, boyut vb. detaylar)
<p>Veri Seti Adı: Fire Dataset (Kaggle)</p> <p>Link: https://www.kaggle.com/datasets/phylake1337/fire-dataset</p> <p>Açıklama: Veri seti fire_images ve non_fire_images olmak üzere iki klasörden oluşmaktadır. Bu klasörler doğrudan ikili sınıflandırma (fire ve non-fire) için uygundur. Kaggle Fire Dataset'i toplam 999 görüntü içerir, 755 yangın görüntüsü ve 244 yangın olmayan görüntüden oluşur.</p> <p>Etiketleme: fire_images klasöründeki görüntüler '1' (yangın var) etiketi, non_fire_images klasöründekiler ise '0' (yangın yok) etiketi ile temsil edilmiştir.</p> <p>Veri Miktarı: Veri setindeki tüm görüntüler kullanılmıştır. Bu görüntülerden 755 adeti yangın ('1'), 244 adeti ise yangın yok ('0') sınıfına aittir. Sınıflar arası dengesizlik mevcuttur (yaklaşık %75 yangın, %25 yangın olmayan).</p> <p>Girdi İşleme: Görüntüler okunmuş, 128x128 piksel boyutuna yeniden boyutlandırılmış ve piksel değerleri 0-1 e göre normalize edilmiştir. Çeşitli renk uzaylarına (BGR, HSV, YCbCr) dönüşümler yapılmıştır.</p> <p>Öznitelik Çıkarımı: Her görüntüden aşağıdaki öznitelikler çıkarılmıştır:</p> <p>Renk Histogramları: HSV uzayından H ve S kanalları, YCbCr uzayından Cb ve Cr kanallarının histogramları. Her kanal için 100 kova kullanılmıştır.</p> <p>LBP: Gri tonlamalı görüntülerden yarıçap 3 ve 24 nokta kullanılarak LBP histogramı çıkarılmıştır (uniform metodu).</p> <p>HOG: Gri tonlamalı görüntülerden 9 orientation, (8, 8) pixels_per_cell, (2, 2) cells_per_block parametreleri ile HOG vektörü çıkarılmıştır (L2-Hys block normu).</p> <p>Öznitelik Vektörü: Çıkarılan tüm öznitelik vektörleri birleştirilerek her görüntü için tek bir öznitelik vektörü oluşturulmuştur. Birleştirilmiş ham öznitelik vektörünün boyutu 8526 şeklindedir.</p> <p>Öznitelik Ölçeklendirme: Birleştirilmiş öznitelik vektörleri, model eğitime uygun hale getirmek için Standard Scaler kullanılarak ölçeklendirilmiştir. Ölçeklendirilmiş öznitelik vektörünün boyutu 8526 şeklindedir.</p> <p>Veri Seti Adı: D-Fire Dataset</p> <p>Link: https://drive.google.com/drive/folders/1DWgsQLVgkLM8m-VcugHNpD5WYDbyYp5 (github link: https://github.com/gaiasd/DFireDataset?tab=readme-ov-file)</p> <p>Açıklama: Bu veri seti makine öğrenmesi ve özellikle nesne tespiti algoritmaları kullanılarak yangın ve duman tespiti için tasarlanmıştır. Görüntülerdeki yangın ve duman bölgeleri bounding box ile işaretlenmiştir. Etiketler YOLO formatında sağlanmıştır. Veri seti düşük güçlü ve kaynak kısıtlı cihazlar için otomatik yangın tespit sistemleri geliştirmek amacıyla kullanılmış ve bu konuda bir makale yayınlanmıştır.</p> <p>Veri Miktarı: D-Fire veri seti 21.000'den fazla görüntü içermesine rağmen, bilgisayarın işleme gücünün yetersizliğinden dolayı bu çalışmada train klasöründen seçilen toplam 1629 görüntü kullanılmıştır. Bu görüntülerden 640 adeti yangın içeren ('1'), 663 adeti ise yangın içermeyen ('0') sınıfa aittir. Etiket belirleme süreci tamamlanan 1629 görüntü başarılı bir şekilde işlenmiştir.</p>

Girdi İşleme: Görüntüler okunmuş, 128x128 piksel boyutuna yeniden boyutlandırılmış ve piksel değerleri 0-1 e göre normalize edilmiştir. Çeşitli renk uzaylarına (BGR, HSV, YCbCr) dönüşümler yapılmıştır.

Öznitelik Çıkarımı: Her görüntüden aşağıdaki öznitelikler çıkarılmıştır:

Renk Histogramları: HSV uzayından H ve S kanalları, YCbCr uzayından Cb ve Cr kanallarının histogramları. Her kanal için 100 kova kullanılmıştır.

LBP: Gri tonlamalı görüntülerden yarıçap 3 ve 24 nokta kullanılarak LBP histogramı çıkarılmıştır.

HOG: Gri tonlamalı görüntülerden 9 orientation, (8, 8) pixels_per_cell, (2, 2) cells_per_block parametreleri ile HOG vektörü çıkarılmıştır (L2-Hys block normu).

Öznitelik Vektörü: Çıkarılan tüm öznitelik vektörleri birleştirilerek her görüntü için tek bir öznitelik vektörü oluşturulmuştur. Birleştirilmiş ham öznitelik vektörünün boyutu 8526 şeklindedir.

Öznitelik Ölçeklendirme: Birleştirilmiş öznitelik vektörleri, model eğitime uygun hale getirmek için Standard Scaler kullanılarak ölçeklendirilmiştir. Ölçeklendirilmiş öznitelik vektörünün boyutu 8526 şeklindedir.

4. Yöntem 1 (yöntemin açıklaması, adımları, gerekli bölümlerinin uygulama detayları)

Gerekli Kütüphanelerin ve Yardımcı Fonksiyonların İmport Edilmesi: Veri işleme, öznitelik çıkarımı, öznitelik mühendisliği, modelleme ve değerlendirme için gerekli kütüphaneler (OpenCV, Scikit-learn, LightGBM, numpy vb.) ve projeye özel olarak geliştirilen yardımcı fonksiyonlar yüklenmiştir. Yardımcı fonksiyonlar modularity sağlamak amacıyla tasarlanmıştır.

Veri Yükleme ve Öznitelik Çıkarımı: Belirtilen veri setinden görüntüler döngüsel olarak okunmuştur. Her görüntü belirlenen hedef boyuta (128x128) yeniden boyutlandırılmış ve piksel değerleri normalize edilmiştir. Ardından farklı renk uzaylarına (HSV, YCbCr) dönüştürülerek HSV'den H ve S kanalları, YCbCr'den Cb ve Cr kanallarının renk histogramları hesaplanmıştır. Gri tonlamalı görüntülerden LBP (radius=3, n_points=24, method='uniform') ve HOG (orientations=9, pixels_per_cell=(8,8), cells_per_block=(2,2), block_norm='L2-Hys') öznitelikleri çıkarılmıştır. Bu öznitelik çıkarım adımı renk, doku ve şekil bilgilerini yakalamayı hedeflemiştir.

Öznitelik Birleştirme ve Temel Ölçeklendirme: Çıkarılan farklı öznitelik türlerine ait vektörler (histogramlar, LBP, HOG) tek bir yüksek boyutlu öznitelik vektöründe (8526) birleştirilmiştir. Bu bileşik vektör; makine öğrenmesi modellerinin performansını artırmak amacıyla StandardScaler kullanılarak temel ölçeklendirme işlemine tabi tutulmuştur. Bu adım farklı özniteliklerin değer aralıklarındaki farklılıkları gidermeyi amaçlar.

Verinin Bölünmesi: Ölçeklendirilmiş öznitelik vektörleri ve karşılık gelen etiketler, model eğitimi ve nihai değerlendirme için eğitim (%80) ve test (%20) setlerine ayrılmıştır. Sınıf dağılımının eğitim ve test setlerinde korunması için StratifiedKFold stratejisi (5 fold) kullanılmıştır. Bu KFold yöntemi sınıf dağılımındaki eşitsizliklere önem vermesi açısından tercih edilmiştir. Eğitim seti boyutu (1303, 8526), test seti boyutu (326, 8526) şeklindedir.

Öznitelik Mühendisliği ve Farklı Öznitelik Setlerinin Oluşturulması: Ölçeklendirilmiş eğitim verisi üzerinde öznitelik seçimi yöntemleri uygulanarak farklı boyut ve içeriğe sahip öznitelik setleri oluşturulmuştur. Uygulanan yöntemler şunlardır:

Korelasyon Analizi (ANOVA F-value): SelectKBest ve f_classif fonksiyonları kullanılarak, sınıf etiketi ile en yüksek korelasyona sahip olduğu istatistiksel olarak belirlenen (ANOVA F-value'ya göre) öznitelikler seçilmiştir. %75 (6394 öznitelik) ve %50 (4263 öznitelik) oranları denenmiştir.

Recursive Feature Elimination (RFE): Bir estimator (bu uygulamada Logistic Regression kullanılmıştır) kullanılarak öznitelikler belirlenen sayıda öznitelik kalana kadar yinelemeli olarak elenmiştir. %75 (6394 öznitelik) ve %50 (4263 öznitelik) oranları (step=0.1 ile) denenmiştir.

Bu seçim adımları, 'Ölçeklendirilmiş (Seçim Yok) - Scaled_All (8526 öznitelik)', 'Ölçeklendirilmiş + Korelasyon Seçimi - Scaled_Corr75% (6394 öznitelik), Scaled_Corr50% (4263 öznitelik)', 'Ölçeklendirilmiş + RFE Seçimi - Scaled_RFE75% (6394 öznitelik), Scaled_RFE50% (4263 öznitelik)' senaryolarını temsil eden farklı öznitelik setleri oluşturmuştur. **(Gereksinimlerde belirtilen PCA yöntemi mevcut uygulamada yer alamamaktadır ve ileride yapılacaklar bölümüne taşınmıştır)**

Model Eğitimi ve Hiperparametre Optimizasyonu: Belirlenen Makine Öğrenmesi modelleri (SVM, LightGBM, MLP) oluşturulan her bir öznitelik seti üzerinde eğitilmiş ve hiperparametreleri optimize edilmiştir. Optimizasyon için RandomizedSearchCV ve 5-fold cross-validation (StratifiedKFold) kullanılmıştır. Her model-öznitelik seti kombinasyonu için belirlenen hiperparametre uzayında (notebook kodunda detaylı belirtilmiştir) arama yapılmış ve en iyi cross-validation F1 performansı veren hiperparametre kombinasyonu belirlenmiştir.

Performans Karşılaştırması: Tüm model ve öznitelik seti kombinasyonlarının cross validation ve nihai test seti üzerindeki performansları karşılaştırılmıştır. Bu karşılaştırma Deney Sonuçları ve Değerlendirme bölümünde detaylandırılmıştır.

En İyi Modelin Test Seti Üzerinde Değerlendirilmesi: Her model türü için cross-validation performansı en iyi olan öznitelik seti üzerindeki model daha önce ayrılan nihai test seti üzerinde değerlendirilmiştir. Standart sınıflandırma metrikleri (Accuracy, Precision, Recall, F1-Score) ve Confusion Matrix hesaplanarak raporlanmıştır. Ayrıca farklı öznitelik setlerinin aynı model üzerindeki test performansları da karşılaştırılmıştır. Güzel

Model ve Transformersların Kaydedilmesi: Her bir model türü için test seti üzerinde en iyi performansı (F1 skoru) veren model, ilgili öznitelik ölçekleyici ve öznitelik seçici nesneleri, gelecekte tahmin yapmak veya doğrulama yapmak için kullanılmak üzere joblib kütüphanesi ile disk üzerine kaydedilmiştir.

5. Deney Sonuçları ve Değerlendirme

Yapılan deneylerde Yöntem 1'de tanımlanan görüntü özniteliklerine dayalı sınıflandırma pipeline'ı hem D-Fire veri setinin train bölümü hem de Kaggle Fire Dataset üzerinde uygulanarak modellerin performansı değerlendirilmiştir. Temel öznitelikler çıkarıldıktan, ölçeklendirildikten ve farklı öznitelik seçim yöntemleri (Correlation, RFE) ile boyutları düşürüldükten sonra SVM, LightGBM ve MLP sınıflandırıcıları Randomized Search ve 5-fold Stratified Cross-Validation ile optimize edilmiştir. Modellerin performansı F1 skoru üzerinden değerlendirilmiştir.

5.1 D-Fire Veri Seti Sonuçları ve Değerlendirme

D-Fire veri setinin train bölümünden seçilen 1629 görüntü (640 yangın, 663 yangın olmayan, 326 yangın veya yangın olmayan olmayan) kullanılarak yapılan deneylerin sonuçları aşağıda sunulmuştur.

Çapraz Doğrulama Sonuçları (En İyi CV F1 Skoru):

SVM:

Scaled_All (8526 öznitelik): 0.7853

Scaled_Corr75% (6394 öznitelik): 0.7823

Scaled_Corr50% (4263 öznitelik): 0.7860

Scaled_RFE75% (6394 öznitelik): 0.8100

Scaled_RFE50% (4263 öznitelik): 0.8995

LightGBM:

Scaled_All (8526 öznitelik): 0.7643

Scaled_Corr75% (6394 öznitelik): 0.7791

Scaled_Corr50% (4263 öznitelik): 0.7744

Scaled_RFE75% (6394 öznitelik): 0.7770

Scaled_RFE50% (4263 öznitelik): 0.7887

MLP:

Scaled_All (8526 öznitelik): 0.7760

Scaled_Corr75% (6394 öznitelik): 0.7787

Scaled_Corr50% (4263 öznitelik): 0.7795

Scaled_RFE75% (6394 öznitelik): 0.8000

Scaled_RFE50% (4263 öznitelik): 0.8748

Çapraz doğrulama sonuçlarına bakıldığında özellikle RFE ile öznitelik seçiminin SVM ve MLP modellerinin CV F1 skorlarını belirgin şekilde artırma potansiyeli olduğu görülmektedir (SVM Scaled_RFE50% 0.8995).

LightGBM modelinde ise öznitelik seçimi CV skorları üzerinde daha sınırlı bir etkiye sahip olmuştur ve en yüksek CV skoru Scaled_RFE50% ile 0.7887'dir.

Test Seti Sonuçları (F1 Skoru, Accuracy, Precision, Recall):

SVM:

Scaled_All: F1: 0.8378, Acc: 0.8313, Prec: 0.7933, Rec: 0.8875, Conf Matrix: [[129 37], [18 142]]

Scaled_Corr75%: F1: 0.8323, Acc: 0.8282, Prec: 0.7989, Rec: 0.8688, Conf Matrix: [[131 35], [21 139]]

Scaled_Corr50%: F1: 0.8278, Acc: 0.8252, Prec: 0.8012, Rec: 0.8562, Conf Matrix: [[132 34], [23 137]]

Scaled_RFE75%: F1: 0.8393, Acc: 0.8344, Prec: 0.8011, Rec: 0.8812, Conf Matrix: [[131 35], [19 141]]

Scaled_RFE50%: F1: 0.7405, Acc: 0.7270, Prec: 0.6940, Rec: 0.7937, Conf Matrix: [[110 56], [33 127]]

LightGBM:

Scaled_All: F1: 0.8098, Acc: 0.8098, Prec: 0.7952, Rec: 0.8250, Conf Matrix: [[132 34], [28 132]]

Scaled_Corr75%: F1: 0.8207, Acc: 0.8190, Prec: 0.7988, Rec: 0.8438, Conf Matrix: [[132 34], [25 135]]

Scaled_Corr50%: F1: 0.8155, Acc: 0.8098, Prec: 0.7784, Rec: 0.8562, Conf Matrix: [[127 39], [23 137]]

Scaled_RFE75%: F1: 0.7952, Acc: 0.7914, Prec: 0.7674, Rec: 0.8250, Conf Matrix: [[126 40], [28 132]]

Scaled_RFE50%: F1: 0.7964, Acc: 0.7945, Prec: 0.7751, Rec: 0.8187, Conf Matrix: [[128 38], [29 131]]

MLP:

Scaled_All: F1: 0.8267, Acc: 0.8252, Prec: 0.8047, Rec: 0.8500, Conf Matrix: [[133 33], [24 136]]

Scaled_Corr75%: F1: 0.8119, Acc: 0.8067, Prec: 0.7771, Rec: 0.8500, Conf Matrix: [[127 39], [24 136]]

Scaled_Corr50%: F1: 0.7987, Acc: 0.8037, Prec: 0.8038, Rec: 0.7937, Conf Matrix: [[135 31], [33 127]]

Scaled_RFE75%: F1: 0.8274, Acc: 0.8221, Prec: 0.7898, Rec: 0.8688, Conf Matrix: [[129 37], [21 139]]

Scaled_RFE50%: F1: 0.7493, Acc: 0.7393, Prec: 0.7095, Rec: 0.7937, Conf Matrix: [[114 52], [33 127]]

D-Fire Test Seti Sonuçlarının Yorumlanması:

Test seti sonuçlarına göre D-Fire veri setinde çapraz doğrulama skorlarındaki RFE ile artış eğilimi, özellikle RFE50% senaryosunda test setine tam olarak yansımamıştır (SVM RFE50% CV 0.8995 iken Test F1 0.7405) Bu durum küçük veri setlerinde çapraz doğrulamanın potansiyel olarak iyimser sonuçlar verebileceğini veya Randomized Search'ün bu hiperparametre kombinasyonlarında test setine genellemeyen modeller bulunduğunu gösterebilir. D-Fire test seti üzerinde en iyi F1 skoru (0.8393), SVM modelinin Scaled_RFE75% öznitelik seti ile elde edilmiştir. Bu sonuç RFE ile yapılan öznitelik seçiminin D-Fire veri setinde doğru oranda (%75) faydalı olabileceğini göstermektedir. LightGBM ve MLP modelleri de çeşitli öznitelik setlerinde benzer performanslar sergilemiştir ancak SVM RFE75% kombinasyonu en yüksek F1 skoruna ulaşmıştır. Precision ve Recall değerleri incelendiğinde yangın sınıfını tespit etme oranının doğru pozitiflerin tüm pozitif tahminlere oranından genellikle daha yüksek olduğu yani modellerin yangın varlığını tespit etme eğiliminde olduğu, ancak zaman zaman yangın olmayanları da yangın olarak etiketleyebildiği görülmektedir.

5.2 Kaggle Veri Seti Sonuçları ve Değerlendirme

Kaggle Fire Dataset üzerinde (998 işlenen görüntü: 755 yangın, 243 yangın olmayan) yapılan deneylerin sağlanan notebook çıktısına göre elde edilen sonuçları aşağıda sunulmuştur. Başlangıçta 999 görüntü tespit edilmiş; 1 görüntü okuma hatası nedeniyle atlanmış ve 998 görüntü başarıyla işlenmiştir.

Çapraz Doğrulama Sonuçları (En İyi CV F1 Skoru):

SVM:

Scaled_All (8526 öznitelik): 0.9511

Scaled_Corr50% (4263 öznitelik): 0.9577

Scaled_Corr75% (6394 öznitelik): 0.9600

Scaled_RFE50% (4263 öznitelik): 0.9853

Scaled_RFE75% (6394 öznitelik): 0.9707

LightGBM:

Scaled_All (8526 öznitelik): 0.9761
Scaled_Corr50% (4263 öznitelik): 0.9728
Scaled_Corr75% (6394 öznitelik): 0.9769
Scaled_RFE50% (4263 öznitelik): 0.9776
Scaled_RFE75% (6394 öznitelik): 0.9769
MLP:
Scaled_All (8526 öznitelik): 0.9174
Scaled_Corr50% (4263 öznitelik): 0.9349
Scaled_Corr75% (6394 öznitelik): 0.9170
Scaled_RFE50% (4263 öznitelik): 0.9667
Scaled_RFE75% (6394 öznitelik): 0.9375

Kaggle veri setinde D-Fire setine kıyasla genel CV F1 skorları belirgin şekilde daha yüksektir. SVM'de RFE ile yapılan öznitelik seçiminin (özellikle %50) CV performansını belirgin şekilde arttırdığı görülmüştür (0.9853). LightGBM ve MLP modellerinde de farklı öznitelik setleri üzerinde yüksek CV skorları elde edilmiştir.

Test Seti Sonuçları (F1 Skoru, Accuracy, Precision, Recall, Confusion Matrix):

SVM:

Scaled_All: F1: 0.9502, Acc: 0.9250, Prec: 0.9533, Rec: 0.9470, Conf Matrix: [[42 7], [8 143]]
Scaled_Corr50%: F1: 0.9412, Acc: 0.9100, Prec: 0.9290, Rec: 0.9536, Conf Matrix: [[38 11], [7 144]]
Scaled_Corr75%: F1: 0.9467, Acc: 0.9200, Prec: 0.9530, Rec: 0.9404, Conf Matrix: [[42 7], [9 142]]
Scaled_RFE50%: F1: 0.9431, Acc: 0.9150, Prec: 0.9527, Rec: 0.9338, Conf Matrix: [[42 7], [10 141]]
Scaled_RFE75%: F1: 0.9467, Acc: 0.9200, Prec: 0.9530, Rec: 0.9404, Conf Matrix: [[42 7], [9 142]]

LightGBM:

Scaled_All: F1: 0.9539, Acc: 0.9300, Prec: 0.9477, Rec: 0.9603, Conf Matrix: [[41 8], [6 145]]
Scaled_Corr50%: F1: 0.9571, Acc: 0.9350, Prec: 0.9539, Rec: 0.9603, Conf Matrix: [[42 7], [6 145]]
Scaled_Corr75%: F1: 0.9574, Acc: 0.9350, Prec: 0.9481, Rec: 0.9669, Conf Matrix: [[41 8], [5 146]]
Scaled_RFE50%: F1: 0.9574, Acc: 0.9350, Prec: 0.9481, Rec: 0.9669, Conf Matrix: [[41 8], [5 146]]
Scaled_RFE75%: F1: 0.9542, Acc: 0.9300, Prec: 0.9419, Rec: 0.9669, Conf Matrix: [[40 9], [5 146]]

MLP:

Scaled_All: F1: 0.9252, Acc: 0.8900, Prec: 0.9510, Rec: 0.9007, F1 Score: 0.9252, Conf Matrix: [[42 7], [15 136]]
Scaled_Corr50%: F1: 0.9384, Acc: 0.9100, Prec: 0.9716, Rec: 0.9073, Conf Matrix: [[45 4], [14 137]]
Scaled_Corr75%: F1: 0.9356, Acc: 0.9050, Prec: 0.9583, Rec: 0.9139, Conf Matrix: [[43 6], [13 138]]
Scaled_RFE50%: F1: 0.9338, Acc: 0.9050, Prec: 0.9853, Rec: 0.8874, Conf Matrix: [[47 2], [17 134]]
Scaled_RFE75%: F1: 0.9241, Acc: 0.8900, Prec: 0.9640, Rec: 0.8874, Conf Matrix: [[44 5], [17 134]]

Kaggle Test Seti Sonuçlarının Yorumlanması:

Test seti sonuçlarına göre Kaggle veri setinde en yüksek F1 skoru, LightGBM modelinin Scaled_Corr75% ve Scaled_RFE50% öznitelik setleri üzerinde elde edilmiştir (Her ikisi de F1: 0.9574). LightGBM Scaled_Corr50% de çok yakın bir performans göstermiştir (F1: 0.9571). Bu kombinasyonlar ayrıca yüksek Accuracy ve Recall skorlarına da sahiptir. SVM modelleri farklı öznitelik setleri üzerinde yüksek ve birbirine yakın F1 skorları elde etmiştir (0.9412 - 0.9502 aralığında). En iyi SVM test performansı Scaled_All seti ile elde edilmiştir (F1: 0.9502). MLP modelleri de makul sonuçlar vermiş ancak SVM ve LightGBM kadar yüksek performanlara ulaşamamıştır. Hem SVM hem de LightGBM modellerinde Precision ve Recall değerleri genellikle dengeli ve yüksek değerlerdedir, bu da modellerin hem yangın sınıfını doğru tahmin etmede hem de yangın olmayanları doğru sınıflandırmada başarılı olduğunu göstermektedir. SVM'de RFE50% ile elde edilen yüksek CV skoru (0.9853) test setine (F1: 0.9431) tam olarak yansımamıştır, bu da D-Fire sonuçlarındaki benzer bir gözlemi Kaggle setinde de desteklemektedir.

Kaggle veri setindeki daha homojen (sadece yangın/yangın olmayan) yapı ve potansiyel olarak daha belirgin yangın/yangın olmayan ayrımı daha yüksek skorlara katkıda bulunmuş olabilir.

6. Sonuç

Bu ara raporda sunulan Yöntem 1; görüntü özniteliklerine (Renk Histogramları, LBP, HOG) dayalı olarak yangın tespiti yapabilme potansiyelini hem D-Fire hem de Kaggle veri setleri üzerinde yapılan deneylerle göstermiştir. Farklı öznitelik seçim yöntemleri (Correlation, RFE) ve seçilen öznitelik sayılarının model performansı üzerindeki etkisi incelenmiştir.

D-Fire veri setinde SVM Scaled_RFE75% kombinasyonu test setinde en yüksek F1 skorunu (0.8393) elde etmiştir. Bu veri setinde RFE ile yapılan öznitelik seçiminin özellikle SVM ve MLP'nin çapraz doğrulama performansını artırma potansiyeli olduğu görülse de en yüksek CV skorlarının test setine her zaman tam olarak yansımadiğı gözlemlenmiştir. Bu durum veri setinin boyutu veya sınıf dağılımının test performansı üzerindeki etkisine işaret edebilir.

Kaggle veri setinde ise genel olarak daha yüksek performans metrikleri elde edilmiştir. LightGBM Scaled_Corr75% ve Scaled_RFE50% kombinasyonları test setinde en yüksek F1 skoruna (0.9574) ulaşmıştır. SVM modelleri de bu veri setinde yüksek ve kararlı performans sergilemiştir. Kaggle veri setindeki daha homojen (sadece yangın/yangın olmayan) yapı ve potansiyel olarak daha belirgin yangın/yangın olmayan ayrımı daha yüksek skorlara katkıda bulunmuş olabilir. Kaggle veri setinde de RFE50% gibi öznitelik sayısını çok fazla azaltmanın test performansını düşürebileceği görülmüştür (SVM RFE50% örneği).

Her iki veri setindeki deneyler öznitelik mühendisliğinin model performansı üzerinde etkili olduğunu ancak bu etkinin kullanılan modele ve seçilen öznitelik oranına bağlı olarak değiştiğini doğrulamaktadır. SVM'in her iki veri setinde de rekabetçi veya en iyi performanslardan birini sergilemesi dikkat çekicidir ancak literatür araştırmalarından dolayı bunun olacağı öngörülmüştür. LightGBM de Kaggle veri setinde başarılı bir performans göstermiştir. MLP modelleri de makul sonuçlar vermiş ancak en iyi performansa ulaşamamıştır.

Kullanılan veri setlerinin (D-Fire'da sınırlı train bölümü, her ikisinde de sınıf dengesizlikleri, D-Fire'daki smoke durumu) nihai performansı etkileyen faktörler olduğu düşünülmektedir. Yöntem 1'in elle oluşturulmuş özniteliklere dayalı yaklaşımı görüntü tabanlı yangın tespiti için temel bir sonuç alınabildiğini göstermiştir.

7. İleride Yapılacaklar

İyi olur.

PCA ile Boyut İndirgeme: Öznitelik mühendisliği adımı PCA (Principal Component Analysis) yöntemi eklenecektir. Farklı sayıda ana bileşen tutularak yeni öznitelik setleri oluşturulacak ve modellerin bu setler üzerindeki performansları değerlendirilecektir.

Bu da iyi olabilir.

Hiperparametre Uzaylarının Genişletilmesi/İyileştirilmesi: Özellikle Random Search kullanılarak veya sonuçlara göre hiperparametre arama uzayları daha detaylı veya farklı değerleri içerecek şekilde genişletilebilir.

Demoda iyi olur.

PCA VE HP Uzayı geliştirmesi Yöntem 1'e dahildir ancak Yöntem 1'deki teknik sorunlardan dolayı harcanan zaman çok fazla olduğu için bunlara yetiştirilememiştir. Önemli değil.

Yöntem 2'nin Geliştirilmesi: CNN için mimari tasarım, implementasyon, eğitim ve tuning adımlarına başlanacaktır.

8. Yöntem 2 (yöntemin açıklaması, adımları, gerekli bölümlerinin uygulanma detayları)

Demo öncesi uygulanması planlanan ikinci yöntem sıfırdan tasarlanacak bir CNN modeline dayanmaktadır. Bu yöntem ham görüntü piksellerinden otomatik olarak hiyerarşik ve ayırt edici öznitelikler öğrenmeyi amaçlamaktadır.

Veri Ön İşleme: Yöntem 1'de olduğu gibi görüntüler okunacak, belirlenen hedef boyuta (hiperparametre) yeniden boyutlandırılacak ve piksel değerleri normalize edilecektir. Renk uzayı dönüşümleri bu yöntemin

doğrudan girdisi olmayacaktır, CNN ham BGR veya Gri tonlama pikselleri üzerinde çalışacaktır (Girdi kanal sayısı hiperparametre olabilir) Veri artırma teknikleri (döndürme, çevirme, parlaklık/kontrast değişimi) eğitim sırasında aşırı öğrenmeyi önlemek ve modelin genelleme yeteneğini artırmak için kullanılabilir (hiperparametre)

CNN Model Mimarisi Tasarımı: Model, birbirini takip eden Evrişim, Aktivasyon, Havuzlama, Batch Normalization ve Dropout katman bloklarından oluşacaktır.

- Giriş Katmanı: Ham görüntü piksellerini alacaktır.
- Tekrarlayan Evrişim ve Havuzlama Blokları: Ardışık Conv2D, Batch Normalization, Aktivasyon (ReLU, Leaky ReLU; hiperparametre), isteğe bağlı Dropout (hiperparametre) ve MaxPooling2D katmanlarından oluşacaktır. Blok sayısı (hiperparametre), her bloktaki filtre sayısı (hiperparametre, ilerleyen bloklarda artırılabilecek), filtre boyutu (hiperparametre), stride (hiperparametre) ve padding (hiperparametre) ayarlanabilir parametrelerdir. Batch Normalization'ın model eğitimini stabilize etmesi ve öğrenmeyi hızlandırması, Dropout'un ise aşırı öğrenmeyi azaltması beklenmektedir.
- Flatten Katmanı: Evrişim ve havuzlama katmanlarından çıkan yüksek boyutlu özelliği tek boyutlu bir vektöre dönüştürecektir.
- Tam Bağlantılı Katmanlar: Flatten katmanının ardından bir veya daha fazla tam bağlantılı katman gelecektir. Bu katmanlar Dense, Batch Normalization, Aktivasyon (ReLU, Leaky ReLU; hiperparametre) ve isteğe bağlı Dropout (hiperparametre) katmanlarından oluşabilir. Her katmanın nöron sayısı (hiperparametre) ayarlanacaktır.
- Çıkış Katmanı: İkili sınıflandırma problemi için 1 nöronlu bir Dense katmanı ve Sigmoid aktivasyon fonksiyonu kullanılacaktır.

OK

Model Derleme ve Eğitim:

- Loss Function: İkili sınıflandırma için Binary Cross-Entropy kaybı kullanılacaktır.
- Optimizer: Adam seçilecektir ve optimize ediciye özgü hiperparametreler ayarlanacaktır.
- Eğitim Döngüsü: Model, eğitim veri seti üzerinde belirli sayıda epoch (hiperparametre) boyunca eğitilecektir. Eğitim sırasında batch size (hiperparametre) belirlenecektir. Performans takibi ve aşırı öğrenmeyi erken durdurmak için validasyon seti kullanılacaktır.
- Hiperparametre Optimizasyonu: Modelin mimari parametreleri (katman sayıları, filtreler, nöronlar vb.) ve eğitim parametreleri (optimizer, learning rate, epoch, batch size) validasyon seti performansı (F1 skoru) üzerinden optimize edilecektir. Random Search hızından dolayı tercih edilecektir.

Model Değerlendirme ve Raporlama: Eğitilen en iyi model nihai test seti üzerinde Yöntem 1'de kullanılan standart metrikler ve Confusion Matrix ile değerlendirilecek ve sonuçlar raporlanacaktır.

Hibrit Yaklaşım (Zaman Kalırsa): CNN'in evrişim katmanlarından çıkarılan özniteliklerin, klasik ML modellerine (Yöntem 1'deki gibi) girdi olarak verildiği hibrit bir model denenebilecektir.

Olursa çok güzel olur.